

01. Presentación

Ciencia de datos para la toma de decisiones II


**Jorge
Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

Programa de la clase

- Presentación
- Revisión del temario
- Diagnóstico programación
- Verificación de instalación de R y Python
- Revisión mecanismos evaluación
- Recomendaciones uso IA
- Uso de LLMs

Sobre mí



M.C. JORGE JUVENAL CAMPOS FERREIRA.

- * **Analista de datos, México, ¿Cómo vamos? Y Fundación Novagob México**
- * **Columnista en Atiempo.TV Coahuila**

Educación Formal:



Licenciatura:

Ingeniería en Irrigación por la Universidad Autónoma Chapingo. (2009-2014).



Maestría:

Maestría en Economía por El Colegio de México (2016-2018).

Contacto:



GitHub: JuveCampos



LinkedIn: Jorge Juvenal Campos Ferreira



Twitter: @JuvenalCamposF



IG: juvenalcampos.dataviz

Experiencia profesional

- **Analista de datos.**

- CIDE - Laboratorio Nacional de Políticas Públicas.
- México ¿Cómo vamos?
- Fundación Novagob México

- **Profesor**

- Periodismo de datos - Maestría en Periodismo del CIDE
- Tableros en R/Shiny - Datacrunchers

- **Periodista**

- Columna semanal en Atiempo.TV
- Escritor y colaborador en Nexos y Animal Político

Instalación R y Python

- Vamos a verificar que tengan R y Python instalado.



Instalar R

<https://cran.r-project.org/>



Instalar Python

<https://www.python.org/downloads/>



Instalar RStudio

[https://posit-co.translate.goog/download/rstudio-desktop/?
_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc](https://posit-co.translate.goog/download/rstudio-desktop/?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc)

Instalación R y Python

- Vamos a verificar que tengan R y Python instalado.



Instalar R

<https://cran.r-project.org/>



Instalar Python

<https://www.python.org/downloads/>



Instalar RStudio

[https://posit-co.translate.goog/download/rstudio-desktop/?
_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc](https://posit-co.translate.goog/download/rstudio-desktop/?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc)

El curso se va a dar principalmente en R y RStudio, por lo que sí es importante que verifiquen que el programa esté instalado y funcionando.

Sobre ustedes

- ¿Cómo se llaman?
- ¿De donde son?
- ¿Por que están en esta carrera?
- ¿Que tanto saben de Ciencia de Datos?
- ¿Qué herramientas saben usar?
- ¿Qué esperan de este curso?



Propósito del curso

El curso busca que el estudiante:

Diseñe, implemente y comunique soluciones de ciencia de datos de forma integral, combinando el uso de programación en R, análisis estadístico, IA generativa, procesamiento de texto, análisis geoespacial y manejo de datos a gran escala, de tal forma que le ayuden a la toma de decisiones estratégicas basadas en evidencia.

Large Language Models

0.1 Fundamentos teóricos de LLMs

0.2 Utilización de herramientas de LLMs para generación de textos y código

MÉTODOS NO SUPERVISADOS DE APRENDIZAJE DE MÁQUINA.

1.1 INTRODUCCIÓN A MODELOS BASADOS EN DISTANCIA.

1.2 NEAREST NEIGHBOURS.

1.3 K-MEANS.

1.4 K-MEDOIDS.

1.5 HIERARCHICAL CLUSTERING.

1.6 Evaluar la calidad y utilidad de clusters en contextos reales

1.7 Traducir los resultados en segmentos, grupos o patrones accionables

ANÁLISIS GEO-ESPACIAL.

2.1 INTRODUCCIÓN A DATOS GEOESPACIALES.

2.1.1 Introducción al trabajo con datos espaciales (coordenadas, polígonos, shapefiles, etc.).

2.2 MÉTODOS DE MEDICIÓN DE DISTRIBUCIONES GEOGRÁFICAS.

2.3 IDENTIFICACIÓN DE PATRONES Y CLUSTERS EN ESPACIOS GEOGRÁFICOS.

PROCESAMIENTO DE LENGUAJE NATURAL.

3.1 INTRODUCCIÓN AL PROCESAMIENTO NATURAL DE TEXTO (NLP)

3.2 ESTADÍSTICAS BÁSICAS DE TEXTO

3.3 REGULAR EXPRESSIONS

3.4 PROCESAMIENTO DE HTML CON BEAUTIFUL SOUP (Web Scraping)

3.5 REDES Y TEXTO NO ESTRUCTURADO (grafos, enlaces).

3.6 DESCARGA DE TEXTO NO ESTRUCTURADO DE INTERNET

3.7 Descarga de datos desde APIs

ARQUITECTURA DE DATOS.

4.0 Diseñar bases de datos

4.1 BASES DE DATOS: RELACIONALES (SQL), NO RELACIONALES (MONGO, DYNAMO), CSV Y JSON.

4.2 INSTANCIAS, CÓMPUTO DISTRIBUIDO, PROCESAMIENTO EN PARALELO, CONTENEDORES Y MICROSERVICIOS.

DESARROLLO DE UNA NARRATIVA DE COMUNICACIÓN.

4.5.1 Presentación de hallazgos con datos para audiencias no técnicas

4.5.2 Integrar resultados de modelos, análisis espaciales y textuales en informes estratégicos

4.5.3 Argumentar decisiones en base en evidencia y métricas.

Evaluación

Criterios de evaluación:

- * **(30%)** Reto del socio formador
- * **(35%)** Tareas
- * **(35%)** Exámenes

Se realizará un mínimo de dos exámenes, y una serie de tareas relativas a los temas que se revisarán. Tanto Manuel como yo nos encargaremos de construir el examen.

Reto:

Proporcionar herramientas de datos útiles para el área de datos de Global Fund for Women.

Contacto en la contraparte: María de los Ángeles Lasa, PhD
Ejemplo: análisis y detección de discurso machista o misógino.

Reto

Durante este semestre, trabajaremos en colaboración con **Global Fund for Women** en un reto enfocado en el uso de ciencia de datos para potenciar su misión de financiar y fortalecer movimientos sociales alrededor del mundo.

El desafío consistirá en **desarrollar un modelo que tome como insumo principal texto —por ejemplo, documentos, narrativas o descripciones de proyectos— y que pueda aportar valor a la organización en la identificación, clasificación o análisis de información relevante para sus objetivos estratégicos.** Este modelo podrá ser supervisado o no supervisado, según la naturaleza del problema planteado y la estrategia de abordaje del equipo.


Contaremos con la **Dra. María de los Ángeles Lasa**, Gerente del Data Gender Hub, como socia formadora, quien nos guiará para asegurar que la solución propuesta esté alineada con las necesidades reales y el impacto social que busca la organización.



Reglas de clase

- Mantener el respeto hacia compañeros y profesores
- Participar de forma ordenada y respetuosa
- Usar dispositivos electrónicos solo cuando el profesor lo indique
- Realizar actividades correspondientes al curso en desarrollo

Uso de la IA



✓ Se permite usar modelos de IA para el apoyo en la resolución de trabajos, siguiendo los **principios éticos** del uso de la IA en el Tec de Monterrey.

Respeto a la dignidad humana: No manipular ni influir indebidamente en personas.

No maleficencia: Evitar daños físicos, psicológicos, reputacionales o a la privacidad.

Promoción de la autonomía: Fomentar que las personas tomen decisiones informadas.

Equidad: Acceso inclusivo y beneficios compartidos.

Seguridad: Proteger datos y usar entornos seguros.


Veracidad: Contrastar y validar la información generada.

Explicabilidad y transparencia: Entender y declarar el uso de IA.

Responsabilidad: Evaluar consecuencias y actuar con reflexión.

Bienestar social y medioambiental: Uso para el bien común y la sostenibilidad.

Uso de la IA



Sugerencias:

1. Declarar siempre su uso en trabajos individuales y colaborativos
2. Emplear IA para potenciar el aprendizaje, resolver dudas y organizar ideas
3. Citar y referenciar cuando sea necesario (seguir formato APA para Chatbots)

Estudiantes



Docentes



Diagnostico uso herramientas Ciencia de Datos

Test diagnóstico

Saquen lápiz y papel. Escriban en una hoja su nombre y respondan a las siguientes preguntas.



¿Haz utilizado alguna de estas herramientas?

¿Alguna otra?

- R/Rstudio
- Python (que IDE)
- QGIS / ARCGIS o alguna herramienta para hacer mapas
- Algún modelo LLM

Del uno al 10, ¿Cómo te consideras de experto en el manejo de R/Python? ¿Por qué?

Del uno al 10, ¿Cómo te consideras en el uso de IA / LLMs? ¿Por qué?

¿Qué es lo más **complejo/complicado o elaborado** que has hecho con IA?

¿Que **temas de datos** te interesan? (Educación, Finanzas, Estadísticas nacionales, manejo de texto, datos geográficos, etc).

¿Qué métodos de **Machine Learning** conoces?
¿Para que sirven o para que los usas/has usado?

¿Haz escuchado alguna noticia sobre la IA últimamente? ¿Cuales? ¿Qué **opinión** te generan?

Modelos LLM

Introducción a los Modelos de Lenguaje

Un sistema de IA que **procesa y genera texto** en lenguaje natural, aprendiendo patrones a partir de **grandes** cantidades de datos.

Ejemplo: Predecir la palabra que sigue en una frase.



Usos comunes de los LLMs

Usos Comunes de los LLMs



Redacción y edición de textos



Explicaciones y tutorías




Resumen de documentos



Simulación de diálogos o roles



Resolución de dudas



Generación de código



****Las imágenes no se generan estrictamente en un modelo LLM, sino que se generan en otro tipo de modelos.***

¿Cómo funciona un LLM?

1. Texto de entrada → **Tokenización** (palabras a números).
2. **Procesamiento** con redes neuronales (capas de **atención**).
3. Predicción de la **siguiente palabra** según el contexto.
4. Respuesta generada en texto natural.



$$A(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$



¿Cómo funciona un LLM?

1.Revisar video:

<https://www.youtube.com/watch?v=awGfhmsN7Lc>



Fundamentos de Ingeniería de Prompts

Fundamentos de ingeniería de prompts

La “**ingeniería de prompts**” trata de incidir en las instrucciones que se le brindan a un LLM, de tal manera que:

- 1) Se transmita al modelo de manera inequívoca lo que se espera de él.
- 2) Lograr que el modelo genere respuestas consistentes y predecibles ante inputs similares
- 3) Obtener los mejores resultados con la menor cantidad de tokens posibles, optimizando tanto costos como tiempos de procesamiento.

La **calidad** de la respuesta depende directamente de la claridad, el contexto y la estructura de la instrucción.



Fundamentos de ingeniería de prompts

★ **Prompt:** Es la instrucción o pregunta que le damos al modelo para que genere una respuesta. La calidad del *prompt* influye directamente en la calidad de la respuesta.

Ingredientes mínimos de un buen prompt

Enfoque: La actividad que queremos que realice el modelo.

Contexto: La información previa que queremos que el modelo tome en consideración al momento de procesar el prompt

Límites: Lo que el modelo debe o no debe incluir en su respuesta

Rol: El rol que debe asumir el modelo al momento de dar la respuesta.

Ejemplos de Prompts

Prompt sencillo

Realiza una investigación completa sobre el INFONAVIT de México. Incluye su historia, funcionamiento actual, noticias recientes y cualquier dataset disponible público. Proporciona información detallada y actualizada.

¿Cuál dará el mejor resultado?

Prompt más elaborado

```
<rol>
Actúa como un investigador especializado en instituciones de vivienda de México con experiencia en análisis de políticas públicas y
manejo de datos gubernamentales.
</rol>

<enfoque>
Realizar una investigación exhaustiva y estructurada sobre el Instituto del Fondo Nacional de la Vivienda para los Trabajadores
(INFONAVIT), abarcando múltiples dimensiones: histórica, institucional, operativa y de disponibilidad de datos.
</enfoque>

<contexto>
El INFONAVIT es una institución tripartita mexicana creada en 1972 que administra el fondo de vivienda de los trabajadores formales. Es
crucial para el sector habitacional mexicano y maneja grandes volúmenes de datos sobre créditos, viviendas y trabajadores cotizantes. La
investigación debe considerar su evolución, reformas recientes, impacto socioeconómico y transparencia en datos.
</contexto>

<tareas_especificas>
1. Investigar la historia institucional del INFONAVIT desde 1972 hasta la actualidad
2. Analizar noticias y desarrollos recientes (últimos 2 años)
3. Identificar y catalogar todos los datasets públicos disponibles
4. Examinar programas actuales y productos crediticios
5. Evaluar el marco regulatorio y reformas recientes
</tareas_especificas>

<limites>
- NO incluir información de otras instituciones de vivienda sin relación directa con INFONAVIT
- NO especular sobre datos no públicos o confidenciales
- NO incluir opiniones políticas partidistas
- Sí incluir únicamente fuentes verificables y oficiales
- Sí proporcionar enlaces directos a datasets cuando sea posible
- Sí mantener un enfoque analítico y objetivo
</limites>

<formato_salida>
Estructura la investigación en las siguientes secciones:
1. Resumen ejecutivo
2. Historia institucional
3. Marco legal y regulatorio actual
4. Programas y productos actuales
5. Noticias y desarrollos recientes (2023-2025)
6. Datasets disponibles (con URLs directas)
7. Análisis de transparencia y acceso a información
8. Conclusiones y recomendaciones para investigadores
</formato_salida>

<fuentes_prioritarias>
- Sitio oficial de INFONAVIT
- Portal de datos abiertos del gobierno mexicano
- INAI (Instituto Nacional de Transparencia)
- Informes anuales oficiales
- Boletines de prensa institucionales
- Bases de datos del IMSS relacionadas
</fuentes_prioritarias>
```

Ejercicio

Redacte un *prompt* para investigar un tema que le sea de interés.

Redáctelo tomando en cuenta **Enfoque, Contexto, Límites y Rol**.

Utilice la sintaxis XML del ejemplo anterior (*envolver cada elemento en los símbolos ">" y "<"*). ¿Considera que redactar este prompt le representa alguna ventaja?