

06. Del tidyverse a los modelos basados en distancia

Ciencia de datos para la toma de decisiones II

Jorge

Juvenal

Campos Ferreira

✉ juvenal.campos@tec.mx

Programa de la sesión de hoy

- Terminar el ejercicio de la clase pasada
- Repaso de conceptos básicos antes de meternos a ML
- Revisión del concepto de distancia
- Revisión del Modelo kNN (k-vecinos cercanos)

Conceptos – Fundamentos previos

¿Qué es un data.frame/tibble?



Estructuras en R para guardar tablas; tibble es una versión más amigable y moderna.

	<i>Name</i>	<i>Team</i>	<i>Number</i>	<i>Position</i>	<i>Age</i>
0	Avery Bradley	Boston Celtics	0.0	PG	25.0
1	John Holland	Boston Celtics	30.0	SG	27.0
2	Jonas Jerebko	Boston Celtics	8.0	PF	29.0
3	Jordan Mickey	Boston Celtics	NaN	PF	21.0
4	Terry Rozier	Boston Celtics	12.0	PG	22.0
5	Jared Sullinger	Boston Celtics	7.0	C	NaN
6	Evan Turner	Boston Celtics	11.0	SG	27.0

Conceptos – Fundamentos previos

¿Qué es dplyr? ¿Cuales son los principales “verbos” de dplyr?


Paquete del *tidyverse* para trabajar con datos como `filter()`, `mutate()`, `summarise()`.



Conceptos – Fundamentos previos

¿Qué es ggplot?

Sistema para hacer gráficas en R basado en capas (*Grammar of Graphics*).



Conceptos – Fundamentos previos

¿Qué es Grammar of graphics?

Grammar of graphics: es una teoría para construir visualizaciones desarrollada por **Leland Wilkinson** (1999).

La idea es que cualquier gráfico puede descomponerse en un conjunto de **componentes básicos** (también, como si fueran piezas de lego) que combinados, generan casi cualquier visualización. En lugar de pensar en “tipos de gráficas” (barras, líneas, dispersión), se piensa en **reglas y capas** que describen cómo se traduce la información en elementos visuales.

Conceptos – Fundamentos previos



¿Qué son las pipas %>% y |>?

Son operadores para encadenar funciones paso a paso, de manera legible.

¿Qué son los operadores?

Son símbolos que indican una operación a realizar sobre uno o más operandos (números, vectores, listas, data.frames, etc.).


Los más comunes son:

- **+ - * /** : Suma, resta, multiplicación, división
- **^** : Potencia
- **/%/** : División entera (sin residuo)
- **%%** : Residuo (módulo)
- **:** : Secuencia
- **<, <=, >, >=, ==, !=** : Comparación (menor qué, menor o igual, mayor qué, mayor o igual, igual, diferente)
- **\$** : Acceder a una columna de un data.frame
- **[[]]** : Acceder a un elemento de una lista
- **&, |** : “and” y “or”, para unir comparaciones en condiciones lógicas
- **<-** : Flechita de asignación
- **%*%** : Multiplicación matricial
- **%in%** : Pertenencia a algo
- **%>%** : Pipa del tidyverse
- **::** : Acceder a las funciones de un paquete
- **?** : Obtener ayuda (sobre una función).
- **??** : Obtener ayuda de internet.
- **~** : Fórmula

Conceptos – Fundamentos previos

¿Qué es importar datos?

Traer datos externos a la sesión de R. Se realiza con funciones de importación como `readxl::read_excel()` o `read_csv()`



Conceptos – Fundamentos previos

¿Qué hace `pivot_wider` y `pivot_longer`?

Son funciones para reestructurar las tablas entre formato ancho y formato largo. `pivot_longer` pasa de formato ancho a largo, y `pivot_wider` pasa de formato largo a ancho.

Revisar:

<https://juvenalcampos.com/posts/2020-12-04-pivoteando-bases/>

Conceptos – Estadística descriptiva


¿Qué es son las medidas de tendencia central?

Son los valores que resumen “*el centro*” de los datos (media, mediana, moda).

¿Qué es son las medidas de dispersión?

Son los valores que miden que tan dispersos estan los datos (rango, varianza, desviación estándar)


Conceptos – Estadística descriptiva



Conceptos – Estadística descriptiva

¿Qué es son los outliers?

Son los valores extremos que se salen de lo común. Una regla de identificación es si cae fuera de los brazos del boxplot o si su Z-score es mayor a 3.




Conceptos – Estadística descriptiva


¿Qué es la correlación?

Es el grado en el que dos variables cambian juntas.


Perfect positive
correlation



Zero
correlation




Perfect negative
correlation



Conceptos – Estadística descriptiva

¿Qué es una matriz de correlación?

Es una matriz o tabla que muestra las correlaciones entre muchas variables.



Conceptos – Preprocesamiento

¿Qué es una matriz de datos / variables explicativas / covariantes (X)?

Es la tabla o matriz de datos predictoras, que no incluye la variable a predecir (o la etiqueta de salida).

¿Qué es el vector de etiquetas / variable dependiente / variable a explicar (Y)?

Es una columna que guarda la clase o valor que queremos predecir o analizar.

Conceptos – Preprocesamiento

¿Qué es un proceso de normalización de los valores?

Es cuando transformamos una variable para que sus valores se encuentren entre 0 y 1.

¿Qué es un proceso de estandarización (z-score)?

Es cuando transformamos una variable para que sus valores tengan una distribución con media cero y desviación estandar 1.


En R, esto lo hacemos con la función *scale()*

Machine Learning

Machine Learning



Es el campo de la IA que diseña algoritmos capaces de aprender patrones a partir de los datos, para mejorar su desempeño en una tarea, sin que sea necesario programar todas las reglas explícitamente.

Subconjunto de la IA donde las computadoras aprenden de los datos y mejoran con la experiencia sin ser programadas explícitamente para ello.




Machine Learning

Esto es justo lo que no es Machine Learning



Machine Learning

En términos prácticos, entrenamos un modelo con ejemplos (datos históricos) y luego usamos ese modelo para **predecir** o **decidir** sobre casos nuevos y sobre eso, tomamos decisiones.



Machine Learning

Formas de clasificar los modelos de Machine Learning:

Por función

- **Regresión:** Modelos diseñados para predecir valores numéricos continuos como salida. Aprenden la relación entre variables independientes, X , y variables dependientes, Y .
- **Clasificación:** Algoritmos cuyo propósito es asignar etiquetas o categorías a las instancias de entrada, X . Es decir, predicen clases discretas (categorías).

Por tipo de aprendizaje

- **Supervisado:** es un tipo de Machine Learning donde entrenas un modelo con pares entrada-salida (x,y) ya etiquetados para que el modelo aprenda una función $f: x \rightarrow y$ que prediga la salida correcta en datos nuevos.
- **No supervisado:** Paradigma donde el modelo se entrena usando datos no etiquetados, es decir, sin conocer previamente la respuesta para esos ejemplos. Sirve para detectar patrones, correlaciones o valores atípicos entre las observaciones.

Conceptos – Aprendizaje supervisado

Para entrenar un modelo de machine learning se requieren:

Base de entrenamiento

Conjunto de datos que el modelo “ve” para **ajustar sus parámetros**. Se usa para aprender patrones (p. ej., los pesos de una regresión o simplemente “guardar” instancias en kNN).

Claves:


- Debe ser **representativa** del problema.
- **No** se usa para evaluar desempeño final (evita sobreajuste).

Base de prueba (test)

Conjunto **separado y nunca visto** por el modelo durante el entrenamiento/selección de hiperparámetros. Sirve para estimar el **desempeño fuera de muestra** (generalización).
Claves:

- No toques el test hasta el final (evita “fugas” de información).
- División típica (orientativa): 70/30 (train/test) o 60/20/20 (train/val/test).

Conceptos - Aprendizaje supervisado



Conceptos – Aprendizaje supervisado

★ Matriz de confusión

Tabla que resume los aciertos y errores de un clasificador comparando etiquetas reales vs. Predichas.

VALORES PREDICCIÓN	VALORES REALES	
	Positivos	Negativos
Positivos	Verdaderos positivos	Falsos Positivos
Negativos	Falsos Negativos	Verdaderos Negativos

Métricas habituales:


- **Exactitud** (Accuracy) = $(VP+VN)/(VP+FP+FN+VN)$
- **Precisión** = $VP/(VP+FP)$
- **Recall** (Sensibilidad) = $VP/(VP+FN)$
- **Especificidad** (TNR) = $VN/(VN+FP)$

Conceptos – Estadística descriptiva

¿Qué es la sesgo, que es varianza?

Sesgo: Error del modelo. Que tanto, en promedio sobre distintos conjuntos de entrenamiento, la predicción se aleja de la verdad.

Varianza: Que tanto cambia la predicción del modelo si cambias el conjunto de entrenamiento.




Modelo	Descripción breve	Función principal
Regresión Lineal	Algoritmo supervisado que ajusta una línea recta (o hiperplano) para modelar la relación entre variables. Predice valores numéricos continuos (ej. precio, cantidad).	Predicción (<i>Regresión</i>)
Regresión Logística	Algoritmo supervisado que estima la probabilidad de pertenecer a una clase. Utiliza la función logística (<i>sigmoide</i>) para producir una salida entre 0 y 1, útil para clasificación binaria .	Clasificación (Binaria)
Máquinas de Vectores de Soporte (SVM)	Algoritmo supervisado que encuentra un hiperplano óptimo que separa las clases con el máximo margen. Puede usarse tanto para clasificación (comúnmente) como para regresión (SVR).	Clasificación (también regresión)
Árbol de Decisión	Modelo en forma de árbol de preguntas y respuestas. Cada nodo interno plantea una pregunta sobre una característica y bifurca los datos según la respuesta, hasta llegar a hojas que son predicciones. Fácil de interpretar.	Clasificación (y Regresión)
Bosque Aleatorio	Ensamble (<i>ensemble</i>) de múltiples árboles de decisión entrenados con diferentes muestras aleatorias. Combina sus predicciones (por votación o promedio) para mejorar la precisión y reducir sobreajuste.	Clasificación y Regresión

Modelo	Descripción breve	Función principal
Naive Bayes	Clasificador probabilístico basado en el Teorema de Bayes que asume independencia entre las características. Es simple y muy eficiente para datos de alta dimensión (texto, por ejemplo).	Clasificación
K-Nearest Neighbors (k-NN)	Algoritmo basado en instancias: para predecir una nueva instancia, busca las “k” más cercanas en el conjunto de entrenamiento (según una medida de distancia) y toma una decisión en base a sus vecinos (por ejemplo, la clase más común).	Clasificación (y Regresión)
K-Means (Clustering)	Algoritmo no supervisado que agrupa datos en K clusters . Iterativamente asigna puntos al cluster cuyo centroide (centro del grupo) esté más cercano y recalcula estos centroides. No requiere etiquetas.	Agrupación (<i>Clustering</i>)
Red Neuronal Artificial	Modelo inspirado en el cerebro humano, compuesto por neuronas artificiales conectadas en capas (entrada, ocultas, salida). Aprende ajustando pesos sinápticos mediante algoritmos como retropropagación. Es muy flexible y capaz de aprender relaciones complejas.	Clasificación y Regresión (Supervisado); también otras variantes (p.ej. redes generativas)

Distancia

A explicar en el pizarrón



Proceso para implementar kNN

1. Preparación del entorno (cargar librerías)
2. Importar datos y realizar análisis exploratorio
3. Visualizar distribuciones de X
4. Análisis de correlación entre variables
5. División de datos en base de entrenamiento y base de prueba
6. Normalización y estandarización de los datos
7. Selección de parámetro k
8. Entrenamiento del modelo final
9. Evaluación del modelo con matriz de confusión
10. Clasificación de nuevos casos