

06. Del tidyverse a los modelos basados en distancia

Ciencia de datos para la toma de decisiones II

Jorge

Juvenal

Campos Ferreira

✉ juvenal.campos@tec.mx

Programa de la sesión de hoy

- Terminar el ejercicio de la clase pasada
- Repaso de conceptos básicos antes de meternos a ML
- Revisión del concepto de distancia
- Revisión del Modelo kNN (k-vecinos cercanos)

Conceptos – Fundamentos previos

¿Qué es un data.frame/tibble?

Conceptos – Fundamentos previos

¿Qué es dplyr? ¿Cuales son los principales “verbos” de dplyr?

Conceptos – Fundamentos previos

¿Qué es ggplot?



Conceptos – Fundamentos previos

¿Qué es Grammar of graphics?


Grammar of graphics: es una teoría para construir visualizaciones desarrollada por **Leland Wilkinson** (1999).

La idea es que cualquier gráfico puede descomponerse en un conjunto de **componentes básicos** (también, como si fueran piezas de lego) que combinados, generan casi cualquier visualización. En lugar de pensar en “tipos de gráficas” (barras, líneas, dispersión), se piensa en **reglas y capas** que describen cómo se traduce la información en elementos visuales.

Conceptos – Fundamentos previos



¿Qué son las pipas `%>%` y `|>`?



¿Qué son los operadores?



Conceptos – Fundamentos previos

¿Qué es importar datos?



Conceptos – Fundamentos previos

¿Qué hace `pivot_wider` y `pivot_longer`?

Conceptos – Estadística descriptiva


¿Qué es son las medidas de tendencia central?



¿Qué es son las medidas de dispersión?



Conceptos – Estadística descriptiva



Conceptos – Estadística descriptiva

¿Qué es son los outliers?



Conceptos – Estadística descriptiva

¿Qué es la correlación?



Conceptos – Estadística descriptiva

¿Qué es una matriz de correlación?



Conceptos – Preprocesamiento

¿Qué es una matriz de datos / variables explicativas / covariantes (X)?



¿Qué es el vector de etiquetas / variable dependiente / variable a explicar (Y)?



Conceptos – Preprocesamiento

¿Qué es un proceso de normalización de los valores?


¿Qué es un proceso de estandarización (z-score)?

Machine Learning

Machine Learning



Es el campo de la IA que diseña algoritmos capaces de aprender patrones a partir de los datos, para mejorar su desempeño en una tarea, sin que sea necesario programar todas las reglas explícitamente.

Subconjunto de la IA donde las computadoras aprenden de los datos y mejoran con la experiencia sin ser programadas explícitamente para ello.




Machine Learning

Esto es justo lo que no es Machine Learning



Machine Learning

En términos prácticos, entrenamos un modelo con ejemplos (datos históricos) y luego usamos ese modelo para **predecir** o **decidir** sobre casos nuevos y sobre eso, tomamos decisiones.



Machine Learning

Formas de clasificar los modelos de Machine Learning:

Por función

- **Regresión:** Modelos diseñados para predecir valores numéricos continuos como salida. Aprenden la relación entre variables independientes, X , y variables dependientes, Y .
- **Clasificación:** Algoritmos cuyo propósito es asignar etiquetas o categorías a las instancias de entrada, X . Es decir, predicen clases discretas (categorías).

Por tipo de aprendizaje

- **Supervisado:** es un tipo de Machine Learning donde entrenas un modelo con pares entrada-salida (x,y) ya etiquetados para que el modelo aprenda una función $f: x \rightarrow y$ que prediga la salida correcta en datos nuevos.
- **No supervisado:** Paradigma donde el modelo se entrena usando datos no etiquetados, es decir, sin conocer previamente la respuesta para esos ejemplos. Sirve para detectar patrones, correlaciones o valores atípicos entre las observaciones.

Conceptos – Aprendizaje supervisado

Formas de clasificar los modelos de Machine Learning:

Base de entrenamiento

Conjunto de datos que el modelo “ve” para **ajustar sus parámetros**. Se usa para aprender patrones (p. ej., los pesos de una regresión o simplemente “guardar” instancias en kNN).

Claves:


- Debe ser **representativa** del problema.
- **No** se usa para evaluar desempeño final (evita sobreajuste).

Base de prueba (test)

Conjunto **separado y nunca visto** por el modelo durante el entrenamiento/selección de hiperparámetros. Sirve para estimar el **desempeño fuera de muestra** (generalización).
Claves:

- No toques el test hasta el final (evita “fugas” de información).
- División típica (orientativa): 70/30 (train/test) o 60/20/20 (train/val/test).

Conceptos - Aprendizaje supervisado



Conceptos – Aprendizaje supervisado

★ Matriz de confusión

Tabla que resume los aciertos y errores de un clasificador comparando etiquetas reales vs. Predichas.

VALORES PREDICCIÓN	VALORES REALES	
	Positivos	Negativos
Positivos	Verdaderos positivos	Falsos Positivos
Negativos	Falsos Negativos	Verdaderos Negativos

Métricas habituales:


- **Exactitud** (Accuracy) = $(VP+VN)/(VP+FP+FN+VN)$
- **Precisión** = $VP/(VP+FP)$
- **Recall** (Sensibilidad) = $VP/(VP+FN)$
- **Especificidad** (TNR) = $VN/(VN+FP)$

Conceptos – Estadística descriptiva

¿Qué es la sesgo, que es varianza?

Sesgo: Error del modelo. Que tanto, en promedio sobre distintos conjuntos de entrenamiento, la predicción se aleja de la verdad.

Varianza: Que tanto cambia la predicción del modelo si cambias el conjunto de entrenamiento.




Modelo	Descripción breve	Función principal
Regresión Lineal	Algoritmo supervisado que ajusta una línea recta (o hiperplano) para modelar la relación entre variables. Predice valores numéricos continuos (ej. precio, cantidad).	Predicción (<i>Regresión</i>)
Regresión Logística	Algoritmo supervisado que estima la probabilidad de pertenecer a una clase. Utiliza la función logística (<i>sigmoide</i>) para producir una salida entre 0 y 1, útil para clasificación binaria .	Clasificación (Binaria)
Máquinas de Vectores de Soporte (SVM)	Algoritmo supervisado que encuentra un hiperplano óptimo que separa las clases con el máximo margen. Puede usarse tanto para clasificación (comúnmente) como para regresión (SVR).	Clasificación (también regresión)
Árbol de Decisión	Modelo en forma de árbol de preguntas y respuestas. Cada nodo interno plantea una pregunta sobre una característica y bifurca los datos según la respuesta, hasta llegar a hojas que son predicciones. Fácil de interpretar.	Clasificación (y Regresión)
Bosque Aleatorio	Ensamble (<i>ensemble</i>) de múltiples árboles de decisión entrenados con diferentes muestras aleatorias. Combina sus predicciones (por votación o promedio) para mejorar la precisión y reducir sobreajuste.	Clasificación y Regresión

Modelo	Descripción breve	Función principal
Naive Bayes	Clasificador probabilístico basado en el Teorema de Bayes que asume independencia entre las características. Es simple y muy eficiente para datos de alta dimensión (texto, por ejemplo).	Clasificación
K-Nearest Neighbors (k-NN)	Algoritmo basado en instancias: para predecir una nueva instancia, busca las “k” más cercanas en el conjunto de entrenamiento (según una medida de distancia) y toma una decisión en base a sus vecinos (por ejemplo, la clase más común).	Clasificación (y Regresión)
K-Means (Clustering)	Algoritmo no supervisado que agrupa datos en K clusters . Iterativamente asigna puntos al cluster cuyo centroide (centro del grupo) esté más cercano y recalcula estos centroides. No requiere etiquetas.	Agrupación (<i>Clustering</i>)
Red Neuronal Artificial	Modelo inspirado en el cerebro humano, compuesto por neuronas artificiales conectadas en capas (entrada, ocultas, salida). Aprende ajustando pesos sinápticos mediante algoritmos como retropropagación. Es muy flexible y capaz de aprender relaciones complejas.	Clasificación y Regresión (Supervisado); también otras variantes (p.ej. redes generativas)

Distancia

A explicar en el pizarrón



Proceso para implementar kNN

1. Preparación del entorno (cargar librerías)
2. Importar datos y realizar análisis exploratorio
3. Visualizar distribuciones de X
4. Análiss de correlación entre variables
5. División de datos en base de entrenamiento y base de prueba
6. Normalización y estandarización de los datos
7. Selección de parámetro k
8. Entrenamiento del modelo final
9. Evaluación del modelo con matriz de confusión
10. Clasificación de nuevos casos