

06. Del tidyverse a los modelos basados en distancia

Ciencia de datos para la toma de decisiones II

Jorge

Juvenal

Campos Ferreira


✉ juvenal.campos@tec.mx

Programa de la sesión de hoy

- Revisar el concepto de distancia en ML
- Revisar los modelos basados en distancia
- Hacer ejemplo de implementación de k-Vecinos Cercanos

Distancia

A explicar en el pizarrón



Proceso para implementar kNN

1. Preparación del entorno (cargar librerías)
2. Importar datos y realizar análisis exploratorio
3. Visualizar distribuciones de X
4. Análisis de correlación entre variables
5. División de datos en base de entrenamiento y base de prueba
6. Normalización y/o estandarización de los datos
7. Selección de parámetro k (hiperparámetro)
8. Entrenamiento del modelo final
9. Evaluación del modelo con matriz de confusión
10. Aplicación a nuevos casos


Hiperparámetros

Los **hiperparámetros** son las configuraciones de un modelo de Machine Learning que el algoritmo no aprende a partir de los datos, sino que deben ser definidos de antemano por el analista antes de la construcción del modelo.

Los hiperparámetros se ajustan con un proceso de “Ajuste de hiperparámetros”, que consiste en buscar y seleccionar los valores adecuados para mejorar su rendimiento.


K-vecinos cercanos

El método de k-vecinos cercanos es un modelo de **clasificación supervisada**, basado en **distancia**, que permite clasificar observaciones nuevas basado en la proximidad que tenga un punto nuevo a clasificar con sus k vecinos más cercanos.



K-medias

El método de K-medias es un método de clasificación o agrupamiento **no supervisado**, que tiene como objetivo la partición de un conjunto de n observaciones en k grupos en el que cada observación pertenece al grupo cuyo valor medio es más cercano.



K-medoides

Es un algoritmo de agrupamiento o clústering parecido a k-medias, con la diferencia de que k-medoids utiliza observaciones como centros y puede trabajar con una métrica arbitraria de distancias.

