

09. Ingesta de datos

Ciencia de datos para la toma de decisiones II

Jorge

Juvenal

Campos Ferreira

✉ juvenal.campos@tec.mx

Programa de la sesión de hoy

- Texto como datos
- Ejemplo de análisis de texto
- Fundamentos: funciones de *stringr*
- Ejercicio con expresiones regulares

Fuentes de los datos

Los datos que utilizamos pueden provenir de varias fuentes:

- **Datos abiertos**
- **Información de la web**
- **APIs**

Datos Estructurados y no estructurados






Los datos estructurados son datos **presentados en una forma predefinida.**

Típicamente (pero no exclusivamente) se presenta de forma tabular, en el que las columnas son variables y las filas observaciones.

Entre estos datos tenemos los archivos de texto plano (*.csv, *.txt), los archivos de Office (*.docx, *.xlsx), los archivos que almacenan información geográfica (*.shp, *.geojson), entre otros, que tienen una estructura definida y son leídos por software de manera nativa.

Los datos no-estructurados. Son datos que no tienen un modelo predefinido de datos o bien no está presentado de forma ordenada. Típicamente son conjuntos de texto, imágenes, números, fechas que no están organizados de forma sistemática.

Entre estos se encuentran los *.pdfs (algunos), los *.pdfs fotografías, así como la información disponible en páginas de internet (catálogos, textos, etc).



Datos estructurados



Los datos estructurados.
Empaquetados y listos para utilizarse.

Datos no estructurados



Los datos no-estructurados.
La información esta ahí, pero hay que extraerla y empaquetarla.

1. Datos Abiertos

Datos Abiertos



“Filosofía y práctica que persigue que **determinados tipos de datos estén disponibles de forma libre para todo el mundo**, sin restricciones de derechos de autor, de patentes o de otros mecanismos de control”.

Open Knowledge foundation

Datos Abiertos



“Filosofía y práctica que persigue que **determinados tipos de datos estén disponibles de forma libre para todo el mundo**, sin restricciones de derechos de autor, de patentes o de otros mecanismos de control”.

Open Knowledge foundation

Datos Abiertos



[Los datos] son abiertos si satisfacen las condiciones siguientes:

1. **Disponibles y de fácil acceso.** (Disponible como un todo desde el principio, a un costo razonable de reproducción, preferentemente desde internet).
2. **Reutilizables y redistribuibles** (los datos deben ser provistos bajo términos que permitan reutilizarlos, redistribuirlos e integrarlos con otros conjuntos de datos).
3. **Facilitan la participación universal** (todos deben poder utilizar, reutilizar y redistribuir la información, sin discriminación en términos de esfuerzo, personas o grupos).

Datos Abiertos (léanlo después)



-Datos Abiertos

[Los datos] son abiertos si su forma de distribución satisface las condiciones siguientes:

- 1.. [Los datos] deben estar disponibles integralmente y a un coste de reproducción razonable, preferiblemente descargable de internet de manera gratuita. Los datos igualmente deben estar disponibles en una forma conveniente para ser modificables.
- 2.. La licencia no debe restringir a nadie la posibilidad de vender o distribuir los datos en sí mismos o formando parte de un paquete hecho de otros conjuntos de datos. Igualmente, la licencia no debe exigir un pago u otro tipo de cuota para esta venta o distribución.
- 3.. La licencia debe permitir hacer modificaciones y obras derivadas y debe permitir que estas sean distribuidas en las mismas condiciones que la obra original. La licencia puede imponer algún tipo de requerimiento referente al reconocimiento y a la integridad.
4. Se deben proporcionar los datos de tal manera que no haya ningún obstáculo tecnológico para ejecutar los actos mencionados anteriormente (formato de datos abiertos). Un formato de Datos abiertos es un formato que pueda ser utilizado sin imponer ninguna restricción (ni de uso monetario, ni de sistema operativo o de otro tipo).
- 5.. Los datos abiertos pueden exigir como condición de uso para la redistribución y la reutilización el reconocimiento a los contribuyentes y a los creadores de los datos. Este reconocimiento no debe imponerse de manera onerosa.
- 6.. La licencia puede requerir como condición que la base de datos, si es modificada o procesada para ser distribuida, tenga un nombre que indique que es otra base de datos diferente.
- 7.La licencia no debe discriminar a ninguna persona o grupo de personas.
8. La licencia no debe restringir a nadie hacer uso de la obra en un ámbito de trabajo específico. Por ejemplo, no puede restringir el uso de la obra en un negocio, o que esta sea utilizada para investigación militar.
9. Los derechos adjuntos a la obra deben aplicarse también a cualquier persona a quién le sea redistribuida sin necesidad de que esta ejecute una licencia adicional

Descarga de datos a través de R y RStudio.

Descarga automatizada 

Descarga de datos a través de R y RStudio.

Ventajas:

- En ciertos casos, te permite hacer las descargas más rápido que si hicieras el trabajo de manera manual
- Es más desafiante intelectualmente 🧐
- Permite a los lectores reproducir tu trabajo
- Permite solo compartir el código, sin tener que subir todos los archivos, dejando la descarga al lector

Funciones a repasar

- `str_c()`, para concatenar texto.
- `curl::curl_download()`, para descargar archivos de internet (principalmente *.zip y *.xlsx)
- `zip::unzip()`, para deszippear o descomprimir archivos de internet.
- Función `for` para realizar bucles o ciclos.

curl::curl_download()

Función que sirve para bajar archivos de internet.

curl::curl_download()

Download file to disk

Description

Libcurl implementation of `C_download` (the "internal" download method) with added support for https, ftps, gzip, etc. Default behavior is identical to `download.file`, but request can be fully configured by passing a custom `handle`.

Usage

```
curl_download(url, destfile, quiet = TRUE, mode = "wb", handle =  
new_handle())
```

Argumentos importantes

- * **url**, la url donde se encuentra el archivo a descargar.
- * **destfile**, como se va a llamar el archivo, una vez que lo descargue en la compu.

zip::unzip()

Función que sirve para descomprimir zips.

Ejemplo de uso:

```
zip::unzip("01_Datos/Datos INE/01.zip",  
          exdir = "01_Datos/Datos INE")
```

Descompresión de un zip ubicado en mi carpeta 01_Datos/Datos INE llamado "01.zip"

Argumentos importantes:

- ***zipfile**, el nombre y ubicación del archivo *.zip que se va a descomprimir.
- ***exdir**, Directorio en el cual vamos a colocar los archivos que resulten de la descompresión.

curl::curl_download()

Función que sirve para bajar archivos de internet.

Ejemplo de uso:

```
curl::curl_download(url = "https://www.inegi.org.mx/contenidos/  
programas/intercensal/2015/tabulados/14_vivienda_mor.xls",  
destfile =  
"01_Datos/Datos Censo/HogaresMorelos.xls")
```

Descarga automatizada del tabulado de viviendas de Morelos para la encuesta intercensal 2015.

Función *for*

Función que sirve para crear bucles o ciclos.

Sintaxis

```
for (elemento in secuencia){  
    Haz_paso_1  
    Haz_paso_2  
    ...  
    Haz_paso_n  
}
```




Fig: operation of for loop

Loops en R con for

Juvenal Campos.

• Quiero hacer un loop:



1. Defino qué quiero hacer...
... y que resultado esperar
(Generalmente hacemos loops para automatizar tareas repetitivas).



2. Lo hago para un caso $n=1$.
(Hago ese proceso una vez)

Loops en R con for

Juvenal Campos.



3. Identifico las partes variables del proceso
(Qué cambiaría en el caso $n=2,3,\dots,n$?)




4. Cambio las partes variables por objetos de R.
(para irlo cambiando en el loop)

Loops en R con for

Juvenal Campos.



5. Construyo el for
(o uso algún otro tipo de loop)
definiendo secuencia, contador
y proceso.



⇒ ¿algo truenó?

↓ Sí



(Muchas veces las cosas truenan cuando hacemos un loop. Hay que ver que excepción surgen cuando lo estamos corriendo y ajustar en caso de que sea necesario)

↓ No



Que algo no haya truenado no significa que estemos bien. Hay que verificar si el resultado obtenido es el deseado y, si no, modificar el proceso para corregirlo.

Ejercicio práctico 01

Suponga que quiere construir el indicador de “Grado promedio de educación” para todos los municipios de México. Para el año 2010 tiene que descargar todos los tabulados de INEGI de educación disponibles en este sitio:

<https://www.inegi.org.mx/programas/ccpv/2010/#tabulados>

Correspondientes a las tablas con la siguiente descripción: *“Población de 15 años y más por municipio, sexo y grupos quinquenales de edad según nivel de escolaridad y grado promedio de escolaridad”*

Establezca un loop el cual le permita descargar los datos de manera automatizada.

2. Web Scrapping

Concepto: Web Scraping

*“Proceso de **extracción de datos almacenados en la web**. Su objetivo es el de recopilar información almacenada en una página web. Podemos “escrapear” artículos web, e-commerce, obtener precios, reseñas, etc.”*
(Platzi).

Concepto: Web Scraping

“La práctica de recolectar datos de manera automatizada a través de internet, sin recurrir a la interacción con una API o al trabajo de un humano recolectando información”.
(Ryan Mitchell, Web Scraping with Python).

Discusión: ¿Qué tan Legal es el WS?



Si tu respuesta es “Sí”,
replantéate lo que
piensas hacer

1. ¿Estoy violando alguna reglamentación local?
2. ¿Estoy violando los **Términos y Condiciones** del sitio?
3. ¿Estoy accediendo a lugares **no autorizados**, o a lugares donde se necesita hacer **login**?
4. ¿Es legal el uso que le voy a dar a los datos o **genera algún perjuicio de algún modo**?
5. ¿Estoy violando alguna ley de **derechos de autor**?
6. ¿Estoy **accediendo a datos personales**, o a datos que pudieran violar el **secreto comercial**?

Concepto: Robots.txt

El **robots.txt** es un archivo que define buenas prácticas a la hora de hacer scraping. Nos dice a qué sitios no quiere la página que accedamos.

Es recomendable seguir estas indicaciones, ya que no hacerlo puede ser **no-ético** y puede tener, en algunos casos, **consecuencias legales**.


<https://platzi.com/robots.txt>

<https://www.linkedin.com/robots.txt>

<https://www.facebook.com/robots.txt>

<https://www.imdb.com/robots.txt>

<https://twitter.com/robots.txt>



Páginas Web



Árbol

Inspector



```
<!DOCTYPE html>
<html lang="es-mx">
  <head>...</head>
  <body>
    <div class="wrapper">
      <header class="header">
        <nav class="nav">
          <a href="/" class="nav-logo">
            
          </a>
          <ul class="nav-links">
            <li>
              <a href="/sobre_mi/">Sobre mí</a>
            </li>
            <li>...</li>
            <li>...</li>
            <li>...</li>
          </ul>
        </nav>
      </header>
      <section class="hero">
        <div class="hero-inner">
          <h1>Juve Campos</h1>
          <h2>Blog personal 🕶️ 💻 </h2>
        </div>
      </section>
      <main class="content" role="main">
        <div class="archive">
          <h2 class="archive-title">2020</h2>
          <article class="archive-item">
            <a href="/2020/07/26/cortando-islas/" class="archive-item-link">Cortando Islas</a>
            <span class="archive-item-date"> 2020-07-26 </span>
          </article>
          <article class="archive-item">
            <a href="/2020/03/03/ejemplos-de-lo-que-se-puede-hacer-en-shiny/" class="archive-item-link">Ejemplos de lo que se puede hacer en shiny</a>
            <span class="archive-item-date"> 2020-03-03 </span>
          </article>
          <article class="archive-item">...</article> = $0
          <article class="archive-item">...</article>
          <article class="archive-item">...</article>
          <article class="archive-item">...</article>
        </div>
      </main>
      <footer class="footer">
        <ul class="footer-links">...</ul>
      </footer>
    </div>
  </body>
</html>
```

Páginas Web



Inspector



Para entrar al inspector, desde el navegador, hay que apretar click-derecho >> inspeccionar elemento

Páginas Web

```
<!DOCTYPE>  
<html>  
  <head>  
    <meta>  
    <title>  
    <link>  
    <script>
```

```
<body>
```

```
  <header>
```

```
  <nav>
```

```
    <main>
```


```
      <section>
```

```
        <article>
```

```
    <aside>
```

```
  <footer>
```

Estructura página web



Dato en la rama correcta



Páginas Web – Tags

```
<main class="content" role="main">
  <div class="archive">
    <h2 class="archive-title">2020</h2>
    <article class="archive-item">
      <a href="/2020/07/26/cortando-islas/" class="archive-item-link">Cortando Islas</a>
      <span class="archive-item-date">2020-07-26</span>
    </article>
    <article class="archive-item">
      <a href="/2020/03/03/ejemplos-de-lo-que-se-puede-hacer-en-shiny/" class="archive-item-link">Ejemplos de lo que se puede hacer en shiny</a>
      <span class="archive-item-date">2020-03-03</span>
    </article>
    <article class="archive-item">...</article> = $0
    <article class="archive-item">...</article>
    <article class="archive-item">...</article>
    <article class="archive-item">...</article>
  </div>
</main>
<footer class="footer">
  <ul class="footer-links">...</ul>
</footer>
</div>
</body>
</html>
```

Cuando hacemos web-scraping de sitios estáticos, vamos a **navegar en el árbol del HTML**, vamos a **anclarnos de los tags y los atributos**, y vamos a **extraer textos y atributos** como, por ejemplo, enlaces de páginas) **para ponerlos en un objeto de R** (vectores, tibbles o listas)

 Texto

 Atributos del HTML-Tag

 El HTML-Tag

Páginas Web – Clases

```
▼ <main class="content" role="main">
  ▼ <div class="archive">
    <h2 class="archive-title">2020</h2>
    ▼ <article class="archive-item">
      <a href="/2020/07/26/cortando-islas/" class="archive-item-link">Cortando Islas</a>
      <span class="archive-item-date"> 2020-07-26 </span>
    </article>
    ▼ <article class="archive-item">
      <a href="/2020/03/03/ejemplos-de-lo-que-se-puede-hacer-en-shiny/" class="archive-item-link">Ejemplos de lo que se puede hacer en shiny</a>
      <span class="archive-item-date"> 2020-03-03 </span>
    </article>
    ► <article class="archive-item">...</article> = $0
    ► <article class="archive-item">...</article>
    ► <article class="archive-item">...</article>
    ► <article class="archive-item">...</article>
  </div>
</main>
▼ <footer class="footer">
  ► <ul class="footer-links">...</ul>
</footer>
</div>
</body>
</html>
```

Las clases son **atributos** de los cuales nos **podemos anclar** para hacer referencia a cierto elemento de la página web.

Cuando hagamos referencia a ellos en el web-scraping, **hay que colocarles un punto** al inicio del nombre de la clase, p. Ej, “*.archive-item*” o “*.archive-item-date*”

Funciones de R



Web Scraping with R

Funciones de R



La librería rvest **nos ayuda a hacer web-scraping.**

Esta librería está **diseñada para trabajar con el tidyverse (%>%)** .

Trata de hacer **fácil las tareas más comunes de web-scraping**, inspirada en la librería *beautifulsoup* de Python.


rvest::read_html(url)



Esta función nos permite descargar a nuestra sesión de R el código HTML de la página a la que le queremos sacar información.

```
library(rvest)
lego_movie <- read_html("http://www.imdb.com/title/tt1490017/")
```

Argumento: **url, cadena de texto.**
La dirección web de la página a la cual le queremos extraer información.



rvest::html_nodes()



Esta función extrae un nodo (rama) del código de la página web que tenemos almacenada en un objeto generado por *rvest::read_html()*

```
rating <- lego_movie %>%  
  html_nodes("strong span")
```

**Atrapa los nodos del tipo "strong span" dentro del código html.*

El resultado de esta función aún no es legible. Hay que transformarlo (como lo que nos salía de las APIs).

rvest::html_nodes()



Los nodos pueden ser uno de los siguientes datos:

- A) Un selector CSS.
- B) Un tag de HTML
- C) Un XPath (Dirección a un elemento en particular)
- D) Una ruta de selección

Y se pueden combinar entre ellos.

rvest::html_text()



Esta función extrae el contenido que se encuentra dentro de un nodo (rama), resultante de la función *rvest::html_node()* o *rvest::html_nodes()*.

```
rating <- lego_movie %>%  
  html_nodes("strong span") %>%  
  html_text() %>%  
  as.numeric()  
rating  
#> [1] 7.7
```

**Acá la rama
seleccionada es
un tag de HTML**

rvest::html_attr()



Esta función extrae el atributo HTML de un nodo que almacene atributos.

□ Atributos



```
▼ <table class="cast_list">
  ▼ <tbody>
    ► <tr>...</tr>
    ▼ <tr class="odd">
      ▼ <td class="primary_photo">
        ▼ <a href="/name/nm0004715/?ref=tt_cl_i1">
           = $0
          </a>
        </td>
        ► <td>...</td>
        <td class="ellipsis"> ... </td>
        ► <td class="character">...</td>
      </tr>
```

rvest::html_attr()




Ejemplos

```
cast <- lego_movie %>%
  html_nodes("#titleCast .primary_photo img") %>%
  html_attr("alt")
cast
#> [1] "Will Arnett"      "Elizabeth Banks" "Craig Berry"      "Alison Brie"
#> [5] "David Burrows"    "Anthony Daniels" "Charlie Day"       "Amanda Farinos"
#> [9] "Keith Ferguson"   "Will Ferrell"     "Will Forte"        "Dave Franco"
#> [13] "Morgan Freeman"   "Todd Hansen"      "Jonah Hill"
```

```
poster <- lego_movie %>%
  html_nodes(".poster img") %>%
  html_attr("src")
poster
#> [1] "https://m.media-amazon.com/images/M/MV5BMTg4MDk1ODExN15BMl5BanBnXkFtZTgwNzIyNjg3MDE@._V1_U"
```

rvest::html_text()



Inspector



```
▼ <a href="https://auto.mercadolibre.com.mx/MLM-903077082-mercedes-benz-clase-gt-s-am2016-factura-original-tomo-auto-_JM#position=1&type=item&tracking_id=04316880-e372-4fe8-92e6-faa5eabc400b" class="ui-search-result_content ui-search-link" title="Mercedes-benz Gt 4.0 S At">
  ▼ <div class="ui-search-result_content-wrapper">
    ▼ <div class="ui-search-item_group ui-search-item_group--price">
      ▼ <div class="ui-search-price ui-search-price--size-medium ui-search-item_group_element">
        ▼ <div class="ui-search-price__second-line">
          ▼ <span class="price-tag ui-search-price__part">
            <span class="price-tag-symbol">$</span>
            <span class="price-tag-fraction">1,650,000</span>
          </span>
        </div>
      </div>
    </div>
    ▼ <div class="ui-search-item_group ui-search-item_group--attributes">
      ▼ <ul class="ui-search-card-attributes ui-search-item_group_element">
        ► <li class="ui-search-card-attributes__attribute">21,000 Km</li>
      </ul>
    </div>
    ▼ <div class="ui-search-item_group ui-search-item_group--title">
      <h2 class="ui-search-item_title ui-search-item_group_element">Mercedes-benz Gt 4.0 S At</h2>
    </div>
    ▼ <div class="ui-search-item_group ui-search-item_group--location">
      <span class="ui-search-item_group_element ui-search-item_location">Estado De México</span>
    </div>
  </div>
</a>
```

Si ya encontramos el dato que estamos buscando, y ya localizamos la rama correcta, lo podemos extraer con la función `html_text()`

rvest::html_text()



```
▼ <a href="https://auto.mercadolibre.com.mx/MLM-903077082-mercedes-benz-clase-gt-s-am2016-factura-original-tomo-auto-_JM#position=1&type=item&tracking_id=04316880-e372-4fe8-92e6-faa5eabc400b" class="ui-search-result_content ui-search-link" title="Mercedes-benz Gt 4.0 S At">
  ▼ <div class="ui-search-result_content-wrapper">
    ▼ <div class="ui-search-item_group ui-search-item_group--price">
      ▼ <div class="ui-search-price ui-search-price--size-medium ui-search-item_group_element">
        ▼ <div class="ui-search-price__second-line">
          ▼ <span class="price-tag ui-search-price__symbol">
            <span class="price-tag-symbol">$</span>
            <span class="price-tag-fraction">1,650,000</span>
          </span>
        </div>
      </div>
    </div>
    ▼ <div class="ui-search-item_group ui-search-item_group--attributes">
      ▼ <ul class="ui-search-card-attributes ui-search-item_group_element">
        <li class="ui-search-card-attributes__attribute">21,000 Km</li>
      </ul>
    </div>
    ▼ <div class="ui-search-item_group ui-search-item_group--title">
      <h2 class="ui-search-item_title ui-search-item_group_element">Mercedes-benz Gt 4.0 S At</h2>
    </div>
    ▼ <div class="ui-search-item_group ui-search-item_group--location">
      <span class="ui-search-item_group_element ui-search-item_location">Estado De México</span>
    </div>
  </div>
</a>
```

```
precios = read_html(url) %>%
  html_nodes(".andes-card") %>%
  html_nodes(".ui-search-result__content-wrapper") %>%
  html_nodes(".ui-search-price") %>%
  html_text() %>%
  str_remove_all(pattern = "\\$|\\,",") %>%
  as.numeric()
```

```
carro = tibble(carro = read_html(url) %>%
  html_nodes(".andes-card") %>%
  html_nodes(".ui-search-result__content-wrapper") %>%
  html_nodes("h2") %>%
  html_text()) %>%
  mutate(marca = str_extract(carro, pattern = "\\w+"))
```

Si ya encontramos el dato que estamos buscando, y ya localizamos la rama correcta, lo podemos extraer con la función `html_text()`

rvest::html_table()



Country/Territory ↕	Recreational ↕	Medical ↕	Notes
Afghanistan	Illegal	Illegal	<i>Main article: Cannabis in Afghanistan</i> Production banned by King Zahir Shah in 1973. ^[9]
Albania	Illegal	Illegal	<i>Main article: Cannabis in Albania</i> Prohibited but plants highly available throughout the country and law often unenforced. ^{[10][11][12]}
Algeria	Illegal	Illegal	<i>Main article: Cannabis in Algeria</i>
Andorra	Illegal	Illegal	<i>Main article: Cannabis in Andorra</i>
Angola	Illegal	Illegal	<i>Main article: Cannabis in Angola</i>
Antigua and Barbuda	Decriminalized	Illegal	<i>Main article: Cannabis in Antigua and Barbuda</i>
Argentina	Decriminalized	Legal	<i>Main article: Cannabis in Argentina</i> Decriminalized for small amounts and private consumption, as ruled by the Supreme Court in 2009. ^[13] Medicinal cannabis legal nationally since 21 September 2017. ^[14]
Armenia	Illegal	Illegal	<i>Main article: Cannabis in Armenia</i>
Australia	Decriminalized in Northern Territory and South Australia . ^{[15][16]} Legal in Australian Capital Territory for personal use but not for sale.	Legal at federal level and in all states. ^[17] Qualifying conditions and other details vary by state. ^[18]	<i>Main article: Cannabis in Australia</i> In September 2019, the Australian Capital Territory became the first state or territory of Australia to legalize recreational use of cannabis. Since 31 January 2020 residents have been allowed to grow two plants and possess 50 g, though sales or other transfer is prohibited, including cannabis seeds. Federal law also remains enforceable. ^[19]

Url = https://en.wikipedia.org/wiki/Legality_of_cannabis

Esta función nos sirve si en la página web ya esta ordenada la función que buscamos en forma de tabla. Nos extrae todas las tablas del sitio y nos las acomoda en una lista.

Ejercicio práctico 02

1. Entre al sitio “https://en.wikipedia.org/wiki/Legality_of_cannabis” y extraiga la tabla de países donde el consumo de cannabis es ilegal.
2. Entre al sitio “<https://atiempo.tv/author/juvenal-campos/>” y extraiga todos los artículos del autor.