

12. Pre procesamiento de texto en R

Ciencia de datos para la toma de decisiones II

Jorge

Juvenal


Campos Ferreira

✉ juvenal.campos@tec.mx

Preprocesamiento


★ **Definición:** Convertir el lenguaje natural en un conjunto de representaciones más limpias y manejables, que los algoritmos puedan interpretar mejor para descubrir patrones, temas o sentimientos.

Textos/documentos




Preprocesamiento


Análisis/modelación



Contexto



El preprocesamiento nos ayuda con el problema de **la alta dimensionalidad de los textos** y la **redundancia de palabras**.



Problemas que ataca el preprocesamiento

1. **Reducir la dimensionalidad**
2. **Evitar redundancia**
3. **Mejorar la señal semántica.** Que los conteos, frecuencias, TF-IDF, embeddings o modelos de Machine-Learning se basen en características relevantes.
4. **Hacer más eficientes y robustos los algoritmos de análisis de textos.**

Conceptos básicos

Token: Un token es una unidad de lenguaje, como una palabra o una frase, que se cuenta o se analiza.

La representación más simple del texto, el modelo de "bolsa de palabras" (bag-of-words), utiliza tokens y su frecuencia, ignorando el orden en que aparecen.

Por ejemplo, en la frase "Good night, good night!" el token "good" aparece dos veces y "night" también.

Ejemplos de tokens:

- * Frases
- * Palabras
- * *Ngramas*
- * Letras/caracteres
- * Ocurrencia de expresiones regulares

Tokenización

Es el proceso de dividir un texto en unidades más pequeñas llamadas *tokens*.

Comúnmente, cada token es una palabra, pero según la necesidad también pueden ser oraciones, caracteres individuales o incluso sub-palabras.

El objetivo es facilitar el análisis: en lugar de procesar un párrafo entero como una cadena larga, se le separa en piezas manejables.

Por ejemplo, al tokenizar "*Hola mundo, ¿cómo estás?*" podríamos obtener los tokens: ["Hola", "mundo", ",", "¿", "cómo", "estás", "?"].

Una vez tokenizado, es más sencillo contar frecuencia de palabras, filtrarlas (como eliminar *stopwords*), o alimentar esos tokens a algoritmos de NLP.

Ilustración sugerida: La imagen de una frase que se “rompe” en fichas o bloques individuales (cada palabra por separado).

Lematización

Técnica para reducir las palabras a su forma base o *lema*, que es la forma que encontraríamos en el diccionario.

A diferencia de simplemente recortar terminaciones, la **lematización utiliza reglas lingüísticas** (y a veces diccionarios) **para mapear, por ejemplo, un verbo conjugado a su infinitivo, o un sustantivo plural a su singular**. Por ello, *corriendo, corrí y corre* se lematizarían todas como "*correr*".

Ejemplo: Un *lematizador* procesando la frase

"Los niños **jugaban** en los parques"

transformaría:

"*jugaban*" -> "*jugar*" y "*parques*" -> "*parque*".

Stemming

Proceso que también reduce las palabras a una raíz común, pero utilizando métodos más simples y mecánicos que la lematización.

En esencia, un algoritmo *stemmer* corta prefijos o sufijos de las palabras para eliminar *morfemas flexivos**. Por ejemplo, aplicando stemming en inglés: "*connections*", "*connected*", "*connecting*" todas podrían truncarse al stem "*connect*"; en español, "*jugar*", "*jugando*", "*jugarán*" podrían reducirse a "*jug*" o "*juga*".

La raíz obtenida no siempre es una palabra completa con significado (a veces son fragmentos), pero suele bastar para agrupar textos que hablan de lo mismo. El stemming es rápido y útil para reducir dimensionalidad (menos formas distintas), aunque sacrifica precisión porque no distingue contextos ni excepciones gramaticales.

Ejemplo: Con un **Porter stemmer** (algoritmo clásico de stemming), las palabras "*corriendo*", "*corre*" y "*corrí*" se recortan todas a "*corr*".

* Los **morfemas flexivos** son las **terminaciones** que se añaden a una palabra para expresar rasgos **gramaticales** (sin crear una palabra nueva). Señalan cosas como **género** y **número** en sustantivos/adjetivos, y **persona, número, tiempo, modo y aspecto** en verbos.

Bolsa de palabras

- Forma de representar texto
- Se construye un bolsón con todas las palabras que aparecen en el *corpus*
- Se ignora el orden de las palabras; solo importa la frecuencia
- Es sencillo y fácil de construir
- Base de muchos modelos de NLP: clasificación de textos, detección de spam, etc.



n-gramas

- Secuencia contigua de n -elementos dentro de una muestra de texto
- Capturan el *contexto local* dentro de una oración o documento

Tipo de N-grama	Secuencias (Ejemplo de salida)
Unigramas ($n = 1$)	"La", "inteligencia", "artificial", "es", "fascinante"
Bigramas ($n = 2$)	"La inteligencia", "inteligencia artificial", "artificial es", "es fascinante"
Trigramas ($n = 3$)	"La inteligencia artificial", "inteligencia artificial es", "artificial es fascinante"

Corpus / Corpora


Un **corpus** (plural: *corpora*) es, en lingüística y procesamiento de lenguaje natural (NLP), una **colección organizada de textos** que se utiliza como base para el análisis del lenguaje.

Es un conjunto de textos: puede contener artículos, libros, entrevistas, discursos, etc.

Suele diseñarse para que sea representativo de un idioma, de un dominio específico o de un estilo, o que presente los documentos necesarios para realizar una investigación.

Sirven para entrenar modelos de lenguaje, estudiar la frecuencia de palabras y expresiones, detectar patrones o desarrollar aplicaciones.

Text Data Hierarchy



Corpora



Corpus



Document



Token

{tidytext}



La librería **tidytext** en R es un paquete diseñado para facilitar el **análisis de texto** siguiendo la filosofía del *tidyverse* (datos organizados en formato de tabla, donde cada fila es una observación y cada columna es una variable).

tidytext **convierte texto no estructurado en datos ordenados**, listos para ser analizados con todas las herramientas del *tidyverse*. Es ideal para quien quiera hacer minería de texto en R sin necesidad de usar estructuras más rígidas como los corpus de tm.


Tokenizando texto:



Algo de vocabulario de procesamiento de lenguaje natural (NLP):

- Bolsa de palabras (*Bag of words*): Las palabras en un documento son independientes
- Cada cuerpo de texto separado es un *documento*
- Cada palabra única es un *término*
- Cada ocurrencia de un *término* es un *token*
- Crear una bolsa de palabras se llama *tokenización*

Text Data Hierarchy



Corpora



Corpus



Document



Token

tidytext::unnest_tokens()



```
tidy_review <- review_data %>%  
  unnest_tokens(word, review)  
tidy_review
```

```
# A tibble: 229,481 x 4  
   date      product      stars word  
   <chr>    <chr>      <dbl> <chr>  
1 2/28/15 iRobot Roomba 650 for Pets      5 you  
2 2/28/15 iRobot Roomba 650 for Pets      5 would  
3 2/28/15 iRobot Roomba 650 for Pets      5 not  
# ... with 229,478 more rows
```

Contar palabras



Counting words

```
tidy_review %>%  
  count(word) %>%  
  arrange(desc(n))
```

```
# A tibble: 10,310 x 2  
  word      n  
  <chr> <int>  
1 the    11785  
2 it      7905  
3 and     6794  
# ... with 10,307 more rows
```


anti_join()



```
tidy_review2 <- review_data %>%  
  unnest_tokens(word, review) %>%  
  anti_join(stop_words)  
tidy_review2
```

```
# A tibble: 78,868 x 4  
  date      product      stars word  
  <chr>    <chr>      <dbl> <chr>  
1 1/12/15  iRobot Roomba 650 for Pets    4 walk  
2 1/12/15  iRobot Roomba 650 for Pets    4 rest  
# ... with 78,866 more rows
```


SnowballC

La librería **SnowballC** en R es una implementación del algoritmo de **stemming (reducción de palabras a su raíz)** de Snowball, desarrollado por Martin Porter.

Su función principal es **reducir las palabras a su forma base o raíz (stem)**.

Ejemplos:

- "corriendo", "correr", "corredor" → "corr"
- "casas", "casita", "casero" → "cas"
- "computadora", "computadoras", "computar" → "comput"

Actividad práctica

1. Cargue el excel que contiene el texto de las mañaneras de la presidenta, el cual se encuentra en la carpeta "01_datos/estenograficas_sheinbaum.xlsx".
 1. Genere un objeto con el contenido de la mañanera más reciente, y guardelo en el objeto *mananera_reciente*
 2. Para el objeto *mananera_reciente*, realice las siguientes actividades:
 1. Elimine todos los acentos
 2. Elimine todos los números
3. Descomponga el texto en tokens de *frases*.
4. Descomponga el texto en tokens de ngramas (3,4 y 5).
4. Descomponga el texto en tokens de *palabras*. Realice un wordcloud con estas palabras. Guarde este resultado en un objeto llamado "palabras"
5. Realice un wordcloud con los *ngramas*
6. Elimine las *stopwords* del objeto *palabras*

Actividad práctica

7. Obtenga el stemming y los lemas de las palabras de la mañanera más reciente. Guarde estos en columnas adicionales del texto
8. Verifique el total de palabras que hay en la columna de palabras, en la columna de términos con el stemming y con la lematización. ¿Cual columna tiene el vocabulario más pequeño?
9. Cuento las palabras más utilizadas en la primera mañanera. Quédese con las primeras 10 en términos de frecuencia.
10. Realice este procedimiento en bucle para el resto de las conferencias.
11. Una vez que tiene las diez palabras más populares de todas las mañaneras, realice un wordcloud con estas palabras.
12. Utilizando zero-shot prompting, trate de determinar de que trató cada conferencia mañanera. Agrupe las mañaneras con temas similares.