

16. Modelado de tópicos

Ciencia de datos para la toma de decisiones II

**Jorge
Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

★ Modelado de tópicos

Es una técnica de aprendizaje **no supervisado** que permite **descubrir temas** latentes (ocultos) dentro de un conjunto grande de documentos o textos.

Su objetivo es **identificar grupos de palabras que tienden a aparecer juntas** y que **representan temas o tópicos recurrentes en los datos**, sin que alguien los defina previamente.



Modelado de tópicos

Imaginemos que cada documento fuese un *smoothie de frutas* y cada tema una fruta diferente.

Cada **documento** (batido) está hecho de una **mezcla** de frutas (**tópicos**) en distintas **proporciones**. Analizando sólo el **sabor** latente (las palabras), el modelado de tópicos intenta **adivinar** qué frutas (temas) y en qué cantidad componen cada batido (documento) sin que nadie le diga de antemano cuáles son esas frutas.

Este proceso es poderoso porque permite **organizar y resumir automáticamente colecciones grandes de textos**, algo complicado de hacer a mano para miles de documentos.

Aplicaciones comunes

- **Análisis de discursos políticos:** identificar qué temas dominan por candidato o por año.
- **Investigación académica:** descubrir áreas de investigación emergentes en artículos.
- **Medios y redes sociales:** agrupar noticias o tuits por tema.
- **Empresas:** analizar comentarios de clientes o encuestas abiertas.



Diferencia con modelos de clasificación

- En modelado de tópicos, **no conocemos de antemano las categorías** latentes
- El modelado de tópicos **nos permite descubrir la estructura oculta** en los datos (modelo no supervisado).
- Aunque están relacionados (en ambos casos clasificamos documentos), en este caso **los documentos pueden tener distintas proporciones de distintos tópicos**




Principal modelo: LDA

El modelo más usado para modelado de tópicos se llama **LDA** (***Latent Dirichlet Allocation, o Asignación de Dirichlet Latente***).

Este modelo supone que:

- * Cada documento está compuesto por una mezcla de temas.
- * Cada tema está formado por una mezcla de palabras.



L para Latente

- Latente, en este contexto, significa ***oculto, no observable*** directamente.
- En el contexto de LDA, se refiere a que los tópicos o temas no están explícitos en los textos: no hay ninguna etiqueta que diga: “este documento es de política” o “este documento es de deportes”.
- El modelo infiere esos temas a partir de los patrones de ocurrencia en las palabras.

Latent Dirichlet Allocation p.2

Podemos pensar que:

- Las **palabras** son lo único que observamos directamente (los datos “visibles”).
- Los **temas** son las ***variables latentes***: causas ocultas que explican por qué esas palabras aparecen juntas.

Ejemplo:

Si en muchos documentos se repiten palabras como “vacuna”, “hospital”, “paciente”, “enfermera”, el modelo *infiere* la existencia de un **tema latente de “salud”**.



Latent Dirichlet Allocation p.3

Formalmente, si **z** representa un tema y **w** una palabra:

$$P(w|z)$$

es la *probabilidad condicional* de que aparezca cierta palabra **w** dado un tema **z** (por ejemplo, “gol” tiene alta probabilidad dado el tema “deportes”).

Y los temas mismos se distribuyen en cada documento (**d**) según:

$$P(z|d)$$

(la proporción de cada tema dentro del documento).

Ninguna de estas distribuciones es directamente observable — de ahí lo de “**latente**”.

Latent Dirichlet Allocation p.4

Nivel	Qué representa	¿Se observa directamente?
Palabras	Contenido literal de los textos	✓ Sí
Tópicos (temas)	Estructura semántica subyacente	✗ No (latente)
Distribuciones (de temas y palabras)	Parámetros inferidos	✗ No (latentes)

Latent Dirichlet Allocation p.5

Hiperparámetros.

- El modelo necesita del **hiperparámetro K**, que es **el número de tópicos** que queremos encontrar.
- La **elección de K** requiere o conocimiento del dominio y de los textos a analizar, o usar criterios de evaluación, o prueba y error probando distintos valores.
- Los tópicos solo son la distribución de palabras. **La interpretación (humana o no) es la que asigna los rótulos o etiquetas** a estos K tópicos.

Representación del problema LDA

1. Se construye una matriz documento-término (**DTM**) donde cada fila es un documento, cada columna es una palabra y cada celda es una frecuencia. Esta será nuestra matriz **D**.
2. El modelo intenta descomponer esta matriz **D** en dos:

$$D \approx T \times W$$

Donde:


- **T** = matriz *documento-tema*
 - **W** = matriz *tema-palabra*
3. El resultado es que:
 - a. Cada **documento** tiene una **distribución de temas**.
 - b. Cada **tema** tiene una **distribución de palabras**.

Implementación en R

En R, el modelado de tópicos se puede implementar con la librería *{topicmodels}*

Esta librería implementa los modelos estadísticos clásicos de modelado de tópicos y permite **explorar la estructura latente de un corpus** de texto.

- Está diseñada para trabajar con matrices documento-término (del paquete tm).
- Permite extraer, evaluar y visualizar los temas más relevantes de un corpus
- Soporta control de parámetros (semillas de probabilidad, número de interacciones, métodos de estimación, etc.).



Implementación en R p.2

Etapa	Función	Resultado
Entrenamiento	<code>LDA()</code> o <code>CTM()</code>	Ajusta el modelo con k temas
Extracción	<code>topics(model)</code>	Tema más probable por documento
	<code>terms(model, n)</code>	Palabras más representativas de cada tema
Evaluación	<code>posterior(model)</code>	Probabilidades de temas y términos
	<code>perplexity(model)</code>	Mide qué tan bien el modelo explica el corpus

Matríz Beta y matríz Gamma

- La matríz Beta es la matríz que nos dá la probabilidad de ocurrencia de w dado Z , es decir: $P(w/z)$

```
tidy(modelo_lda, matrix = "beta")
```

- Por su parte, la matríz gamma nos dice la probabilidad de distribución de cada tema, z para cada documento, d , es decir: $P(z/d)$

```
tidy(modelo_lda, matrix = "gamma")
```

Ejemplo

Utilizando los artículos de **Juvenal Campos** para **A tiempo.TV**, realice un modelado de tópicos para analizar de que temas se hablan en estos artículos. Para ello:

1. Realice el *preprocesamiento* correspondiente
2. Genere la matriz documento-término
3. Realice el modelado de tópicos con la función `topicmodels::LDA()`. Defina usted el número de temas.
4. ¿Cuáles son los temas de los que habla el autor en sus textos? Etiquete manualmente cada uno de esos temas, en función de las palabras o términos con mayor puntaje de ***beta***.
6. A partir de la matriz de ***gammas***... determine la importancia promedio de cada tema en el conjunto de los corpus.

Definiendo el número de temas, K

- Para definir el número óptimo de temas, K, tenemos que tener una medida de evaluación.
- En este caso, esa medida es la perplejidad (★ **Perplexity**). Esta es una medida de qué tan bien una distribución de probabilidad predice una muestra.

$$2^{H(p)} = 2^{-\sum_x p(x) \log_2 p(x)}$$

- Una baja **perplejidad** indica que la distribución de probabilidad es buena para predecir la muestra. A menor **perplejidad**, mejor nuestro modelo. P
- Por lo tanto, como la perplejidad es un valor asociado a un modelo, hay que **generar distintas versiones del modelo, variando el número de temas K**, y ver cual es el valor que minimiza la perplejidad.

Método de Gibbs

El **método de Gibbs** es una técnica de **MCMC (Markov Chain Monte Carlo)** que permite estimar distribuciones posteriores cuando no pueden calcularse de forma analítica. En el caso de LDA, el objetivo es estimar las **distribuciones ocultas de temas en documentos y palabras en temas**.

En pocas palabras:

- En lugar de resolver directamente las ecuaciones bayesianas del modelo (lo cual es muy costoso),
- se **simulan muestras** de las distribuciones de probabilidad de cada variable (temas, palabras, documentos),
- repitiendo este proceso muchas veces hasta que la cadena converge a la distribución real.

Método de Gibbs p.2

El LDA con Gibbs sampling repite lo siguiente muchas veces:

- 1. Toma un documento y una palabra específica.**
- 2. Elimina temporalmente esa palabra** de su asignación actual de tema.
- 3. Calcula la probabilidad condicional** de que esa palabra pertenezca a cada tema, basada en:
 - cuántas veces ese tema aparece en el documento;
 - cuántas veces esa palabra aparece en el tema;
 - y los hiperparámetros α (documento–tema) y β (tema–palabra).
- 4. Reasigna la palabra a un nuevo tema** según esa probabilidad.
- 5. Repite para todas las palabras en todos los documentos.**

Con suficientes iteraciones (burn-in y muestreo estable), el resultado converge a una **buena aproximación** de las distribuciones reales de temas y palabras.

Método de Gibbs p.3

```
library(topicmodels)

lda_model <- LDA(
  dtm,          # matriz documento-término
  k = 5,        # número de temas
  method = "Gibbs", # usa muestreo de Gibbs
  control = list(
    burnin = 2000, # número de iteraciones iniciales que se descartan
    iter = 1000,  # número de iteraciones de muestreo
    thin = 100,   # salto entre muestras
    seed = 1234
  )
)
```